

תובנות אישיות מהפרויקט: שחזור המאמר ECLIPSE

דוח מסכם ומבט רטרוספקטיבי על תהליך השחזור, האתגרים ההנדסיים והמסקנות המחקריות

ECLIPSE (CVPR 2024)	מאמר מקור:	אור בלזר ודניאל צ'יצ'רין	מגישים:
Python, PyTorch, CUDA	סביבת פיתוח:	פרויקט סיום מעשי בקורס תכנות בשפת Python	הקשר הפרויקט:
מניעת שכחה קטסטרופלית (Catastrophic Forgetting) ולמידת מחלקות חדשות ברשתות נוירונים			נושא המחקר:

מבוא ורקע לפרויקט

כשבחרנו בפרויקט שחזור של המאמר ECLIPSE (CVPR 2024) דמיינו שהקושי המרכזי שנעמוד מולו יהיה הבנת הרעיון המדעי המורכב – כלומר, כיצד ניתן ללמד רשת נוירונים לזהות מחלקות חדשות לחלוטין מבלי שהדבר יגרום לה לשכוח את המידע והידע שהיא כבר רכשה בעבר. אולם, המציאות ההנדסית שהתבררה לנו תוך כדי התקדמות העבודה הייתה כמעט הפוכה: דווקא הרעיון המדעי והתיאורטי התגלה כחלק הברור, המהודק והאלגנטי ביותר, בעוד שכל מה שמסביב – ניהול סביבות העבודה, התקנות הספריות, קומפילציה מורכבת של קוד CUDA, וההמתנה הממושכת ואינסופית לטעינה של עשרות אלפי תמונות – הוא שגזל את מרבית הזמן, הסבלנות ומשאבי המחשוב שלנו.

שיעורים הנדסיים מול אתגרים מחקריים

זה היה השיעור הראשון והחשוב ביותר שלקחנו מהפרויקט הנוכחי: שחזור של מחקר אקדמי מוביל הוא קודם כל בעיה הנדסית מורכבת, הרבה לפני שהוא הופך לאתגר אלגוריתמי או תיאורטי. רגע השיא של התסכול, ומיד אחריו של הסיפוק המקצועי, התרחש כאשר נתקלנו בשגיאת קומפילציה קריטית של ה-**CUDA operator**.

הקוד פשוט סירב להתקמפל באופן עקבי, והודעות השגיאה שפלט המהדר היו מאיימות, ארוכות ובלתי מובנות לחלוטין. לאחר שעות ארוכות של חקירה עמוקה, חיטוט בקבצי המקור ובדיקת גרסאות, הסתבר שכל הבעיה נעוצה בשורת קוד בודדת קטנה – קריאה לפונקציה **scalar_type** שכבר אינה נתמכת או ממופת בגרסאות העדכניות של **PyTorch** תיקון של תו בודד החזיר לחיים את הפרויקט כולו. חוויה זו לימדה אותנו עד כמה שברירת יכולה להיות שרשרת התלויות בפרויקט מחקרי מתקדמת, וכמה קריטי לקרוא לעומק ובקפדנות את השגיאה הראשונה שנפלטת, במקום לנסות פתרונות שטחיים באופן אקראי.

תובנה מפתח: פרויקט מחקרי יישומי דורש עמידות הנדסית גבוהה. ללא בסיס יציב של תשתיות, גרסאות וניהול תלויות, גם הרעיון האלגוריתמי הטוב ביותר לא יוכל להתממש.

שיעור משמעותי נוסף נגע ישירות לאופן שבו אנחנו מאמתים ומבקרים כל שלב ושלב בתהליך הפיתוח. בתחילת הדרך, נטינו להניח באופן טבעי שאם תא קוד מסוים ב-Notebook "רץ" מבלי להקפיץ שגיאה מפורשת או לקרוס – הרי שהשלב הצליח. מהר מאוד הבנו שזוהי הנחה מוטעית לחלוטין שמייצרת באגים סמויים.

כך למשל, נתקלנו בפקודת הורדה (download) שהסתיימה לכאורה בסטטוס "הצלחה", אך בפועל הורידה דף שגיאה בפורמט HTML במקום את קובץ המשקלים האמיתי של המודל. מאותו רגע ואילך, אימצנו כלל עבודה פשוט ונוקשה: לכל שלב ב-Pipeline חייב להיות מבחן אימות חד-משמעי. זה יכול להיות קובץ פלט שאנו בודקים באופן אקטיבי את גודלו הפיזי, סרגל התקדמות (Progress Bar) שחייב להגיע ל-100%, או מדד מספרי מדויק שניתן להשוות מול ערך ייחוס ידוע מראש. גישה שיטתית זו הפכה את כל ה-Pipeline למערכת אמינה שניתן להריץ מחדש בביטחון מלא, מתוך ידיעה מוחלטת היכן בדיוק מתרחש הכשל במידה ומשהו משתבש.

הערכת הארכיטקטורה של ECLIPSE

ברמה המושגית והארכיטקטונית, נחשפנו לאלגנטיות יוצאת דופן ברעיון שעומד בבסיס המאמר. במקום הגישות המסורתיות והמיושנות הדורשות אימון מחדש (Fine-Tuning) של מודלי ענק בכל פעם שמופיעות מחלקות חדשות במערכת – תהליך שהוא לא רק יקר להחריד מבחינה חישובית אלא גם גורם לרשת "לשכוח" ידע קודם – המאמר מציע פתרון חלופי מבריק.

השיטה מבוססת על הקפאה (Freezing) מוחלטת של כל משקלי המודל המקורי, ולמידה של אוסף מצומצם וזעיר של **prompts** ייעודיים. מדובר על אימון של כ-1.5% בלבד מכלל הפרמטרים ברשת. מצאנו יופי הנדסי רב בתפיסה הזו, המראה שלא פעם הפתרון החכם והיעיל ביותר אינו טמון בהגברת המורכבות או בעשיית "יותר", אלא דווקא ביכולת המדויקת לגעת ב"פחות".

ניתוח העבודה מול כלי בינה מלאכותית (AI)

היבט נוסף שהפתיע אותנו לטובה היה אופי הדינמיקה והעבודה השוטפת מול כלי ה-AI השונים במהלך הפרויקט. בתחילת הדרך, הציפייה הראשונית והנאיבית שלנו הייתה שהכלי ישמש פשוט כ"כותב קוד" או מהדר אוטומטי שיספק לנו פתרונות מוכנים. בפועל, גילינו שמערכת היחסים הזו מורכבת, עמוקה ומלמדת הרבה יותר.

ה-AI התגלה כעוזר מחקר מצוין בדיוק במשימות הסיזיפיות והמתישות ביותר: פענוח וניתוח הודעות שגיאה סבוכות של מהדרים, הצעת אסטרטגות חכמות לעקיפת צווארי בקבוק בשלב הורדת הנתונים, או הסבר בהיר וממצה של מושגים אקדמיים מופשטים שלא הכרנו קודם לכן. עם זאת, נחשפנו גם לצד הפחות חיובי – נטייתו להזות ולטעות בביטחון עצמי מופרז, להמציא נתיבי קבצים פיקטיביים שאינם קיימים, ולהציע פתרונות קוסמטיים שהסתירו את שורש הבעיה האמיתית במקום לפתור אותה.

הפקנו מכך שלוש מסקנות עבודה מרכזיות מול כלי ה-AI:

- יש לספק לכלי תמיד את השגיאה המלאה והגולמית (**Stack Trace**) ללא קיצורים או סינונים.
- חובה לדרוש מהכלי באופן אקטיבי דרך מוגדרת או קוד בדיקה כדי לאמת שהתיקון המוצע אכן פתר את הבעיה.
- יש להתייחס לכל פלט או פיסת קוד שהכלי מייצר כטיוטה ראשונית בלבד הדורשת בדיקה, אימות וביקורת אנושית קפדנית, ולא כתשובה סופית ומוחלטת.

ללא ספק, החלק המרתק והאהוב עלינו ביותר בפרויקט היה ההתמודדות עם משימת הבונוס המעשית. לאחר שהשקענו מאמצים רבים והצלחנו לשחזר באופן מדויק ומלא את המספרים והמדדים המוצגים במאמר המקורי (ברמת דיוק מרשימה שהגיעה עד לעשירית הנקודה), הרגשנו לראשונה מספיק ביטחון הנדסי כדי לחרוג מגבולות השחזור היבש ולנסות לשפר את המודל בעצמנו.

ההשערה המחקרית שהעלינו הייתה פשוטה: מסכות (masks) המיוצרות עבור מחלקות חדשות נוטות מטבען להיות פחות "בטוחות" ובעלות ודאות נמוכה יותר בהשוואה למחלקות המקוריות. כתוצאה מכך, סף הסינון הדיפולטיבי שנקבע במאמר על ערך של 0.5 הוא קשיח מדי וזורק בטעות מסכות רבות שהן למעשה נכונות. החלטנו לבחון זאת באופן אמפירי והורדנו את סף הסינון לרמה של 0.35.

התוצאות שקיבלנו אישרו את ההשערה שלנו בצורה מובהקת: מדדי הביצוע של המודל השתפרו במעט ובאופן עקבי לחלוטין על פני כל שלושת תרחישי הבדיקה השונים. ברור לנו לחלוטין שמדובר בשיפור צנוע בלבד ואיננו מתיימרים לטעון שגילינו פריצת דרך מדעית חדשה, אך עצם הרגע שבו הפרויקט הפך משחזור פסיבי של עבודה קיימת לניסוי עצמאי, מבוסס השערה ומניע תוצאות משלנו, היה מספק ומעשיר באופן יוצא מן הכלל.

סיכום ומבט לעתיד

במבט לאחור, אילו היינו צריכים להתחיל את הפרויקט הזה מנקודת האפס, היינו משנים את חלוקת הזמנים ומקדישים מראש הרבה יותר משאבים ותשומת לב לשלבי ההתקנה הראשוניים, הכנת הנתונים וניהול הסביבה, במקום להתייחס אליהם כאל "פורמליות טכנית" משעממת שיש לעבור במהירות לפני שמגיעים לחלק המעניין.

מעבר לכל פיסת קוד או פתרון באג טכני, הנכס המרכזי והמשמעותי ביותר שאנו לוקחים איתנו מהעבודה על פרויקט זה הוא תחושת המסוגלות העצמית והביטחון המקצועי: היכולת לקחת מאמר מחקרי מורכב מכנס מדעי מוביל בעולם (CVPR), לצלול לתוכו, להבין את עקרונותיו, להריץ אותו בהצלחה על תשתית המחשוב שלנו, ואפילו להעז ולבצע בו שינויים ושיפורים מוצלחים. עבורנו, החוויה הזו הרגישה הרבה פחות כמו תרגיל אקדמי סטנדרטי ועוד מטלה להגשה בקורס, והרבע יותר כטעימה אמיתית ומרתקת מהאופן שבו נראה מחקר יישומי אמיתי בעולם ההייטק והאקדמיה.